Data Mining

Esercizi di classificazione - Soluzioni

BBS
BOLOGNA BUSINESS SCHOOL

Pre processing bank data

- Il dataset bank-data.arff
  - ✓ 600 istanze
  - ✓ Nessun dato missing

Attributo	Descrizione
Id	Identificatore unico
Age	età del cliente in anni (numeric)
Sex	MALE / FEMALE
Region	inner_city/rural/suburban/town
Income	reddito del cliente (numeric)
children	sposato? (YES/NO)
car	possiede un'automobile? (YES/NO)
save_acct	ha un conto di risparmio? (YES/NO)
current_acct	ha un conto corrente? (YES/NO)
Mortgage	ha un mutuo (YES/NO)
pep	**ha acquistato un PEP (Personal Equity Plan) dopo l'ultimo invio postale? (YES/NO)**

Pre processing bank data

1. Caricare il file e salvarlo in formato ARFF con il nome “bank data.arff”
2. Effettuare un’analisi manuale dei dati mediante visualizzazione
   - ✓ Istogrammi attributo – attributo (da pagina Visualize)
   - ✓ Distribuzioni attributo – attributo – classe (da pagina Visualize)
     - Commentare la distribuzione Income –Children - PEP
3. Eliminare l’attributo ID e salvare nuovamente con il nome “bank data.arff”
4. Discretizzare l’attributo AGE (Equal- frequency 10 bin) e Children (Manualmente) e salvare il dataset con il nome “bank data1.arff”

Classificazione bank data

- Utilizzare i seguenti algoritmi per eseguire la classificazione e commentare il risultato
  - ✓ Valutare il risultato con Cross-validation 10 folds / Use training set / Percentage split
  - ✓ Utilizzare sia il data set discretizzato (bank data1.arff), sia quello non discretizzato (bank data.arff)

1. J48
   - Rappresentare e discutere i decision boundary
2. J48 senza post-pruning (unpruned = True)
   - Visualizzare l'albero di decisione
3. IBk con k=1 e k=5 sul data set non discretizzato (BankData.arff)
   - Dopo aver normalizzato i rimanenti attributi numerici
4. Ripetere la classificazione utilizzando BankData1.arff dopo aver discretizzato anche l'attributo income (equal frequency 10 bins)
   - Salvare il training set nel file BankData2.arff

Classificazione bank data

Bank data1.arff: Discretizzato

J48 – Training set 91.5%

```
   a   b   <-- classified as
 239  35 |   a = YES
  16 310 |   b = NO
```

J48 – Cross val 91.3%

```
   a   b   <-- classified as
 239  35 |   a = YES
  17 309 |   b = NO
```

J48 – Split 88.2%

```
   a  b   <-- classified as
  81 15 |  a = YES
   9 99 |  b = NO
```

Bank data.arff: Non discretizzato

J48 – Training set 92.3%

```
   a   b   <-- classified as
 245  29 |   a = YES
  17 309 |   b = NO
```

J48 – Cross val 89.8%

```
   a   b   <-- classified as
 236  38 |   a = YES
  23 303 |   b = NO
```

J48 – Split 86.8%

```
   a  b   <-- classified as
  81 15 |  a = YES
  12 96 |  b = NO
```

Bank data.arff: Non discretizzato + Split

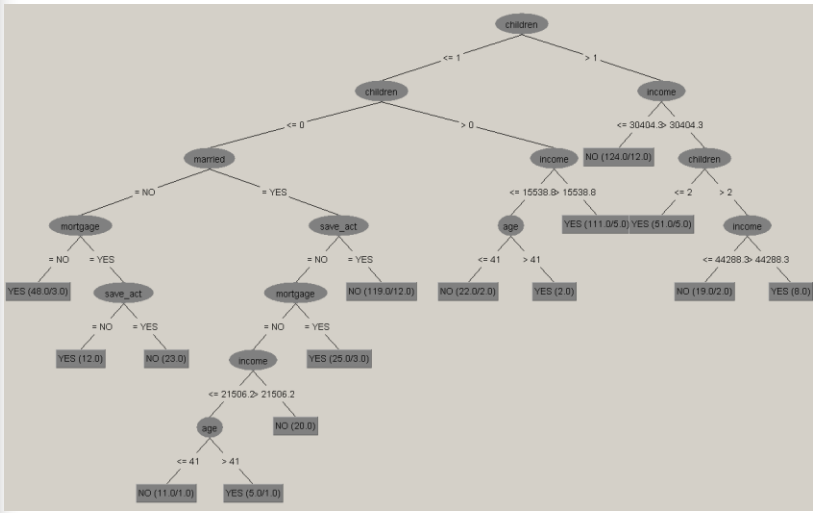

Bank data1.arff: Discretizzato + Split

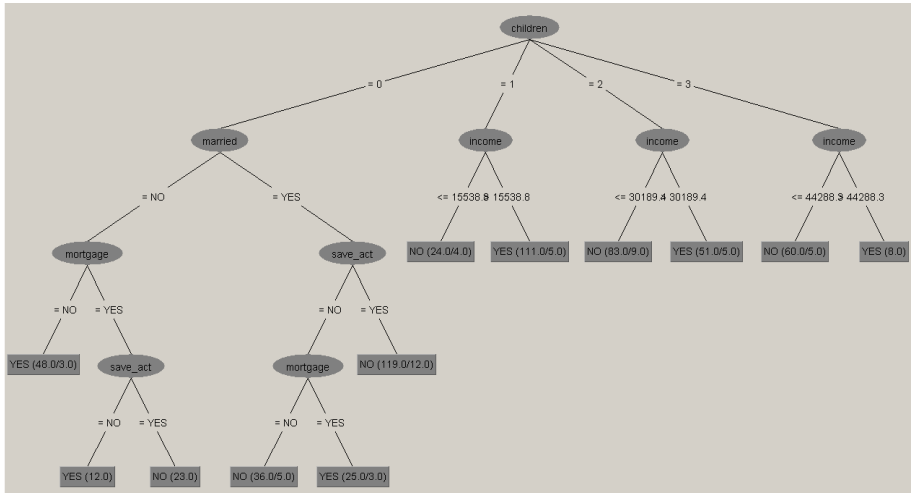

Classificazione bank data

Bank data1.arff: Discretizzato + No pruning

J48 – Training set 95.2%

```
   a   b   <-- classified as
 255  19 |   a = YES
  10 316 |   b = NO
```

J48 – Cross val 89.5%

```
   a   b   <-- classified as
 241  33 |   a = YES
  30 296 |   b = NO
```

J48 – Split 85.3%

```
   a  b   <-- classified as
  81 15 |  a = YES
  15 93 |  b = NO
```

Migliora la classificazione sul training set, peggiora negli altri casi
Fatica a generalizzare! → Overfitting

Bank data1.arff: Discretizzato + Split + No pruning

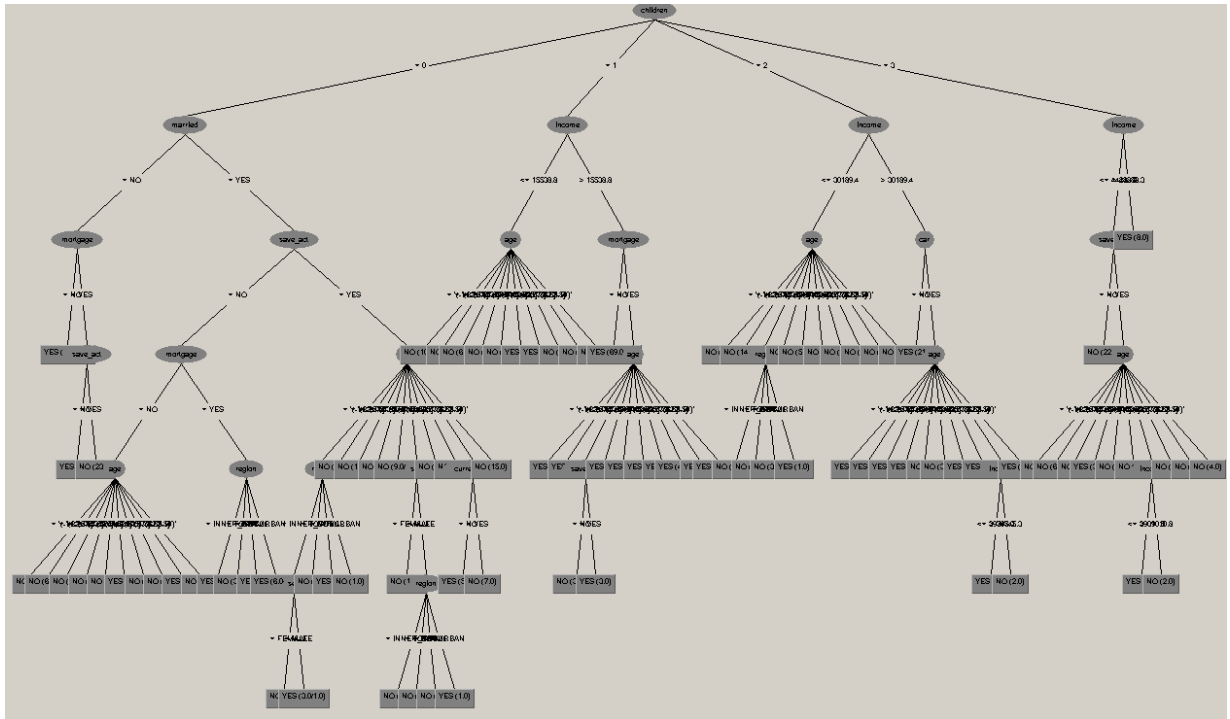

Classificazione bank data

Bank data.arff2: Normalizzato + Discretizzato

IB1– Training set 100%

```
a   b   <-- classified as
274   0 |   a = YES
  0 326 |   b = NO
```

IB1– Cross val 74.7%

```
a   b   <-- classified as
209  65 |   a = YES
 87 239 |   b = NO
```

IB1– Split 70.6%

```
a  b   <-- classified as
76 20 |  a = YES
40 68 |  b = NO
```

Bank data.arff: Normalizzato + Non discretizzato

IB1– Training set 100%

```
a   b   <-- classified as
274   0 |   a = YES
  0 326 |   b = NO
```

IB1– Cross val 64.2%

```
a   b   <-- classified as
171 103 |   a = YES
112 214 |   b = NO
```

IB1– Split 61.3%

```
a  b   <-- classified as
59 37 |  a = YES
42 66 |  b = NO
```

Bank data.arff2: Normalizzato + Discretizzato

IB5 – Training set 82.3%

```
a   b   <-- classified as
217  57 |   a = YES
 46 280 |   b = NO
```

IB5– Cross val 76.3%

```
a   b   <-- classified as
195  79 |   a = YES
 63 263 |   b = NO
```

IB5– Split 75.5%

```
a  b   <-- classified as
73 23 |  a = YES
27 81 |  b = NO
```

Bank data.arff: Normalizzato + Non discretizzato

IB5 – Training set 78.2%

```
a   b   <-- classified as
203  71 |   a = YES
 60 266 |   b = NO
```

IB5 – Cross val 65.2%

```
a   b   <-- classified as
162 112 |   a = YES
 97 229 |   b = NO
```

IB5 – Split 60.3%

```
a  b   <-- classified as
51 45 |  a = YES
36 72 |  b = NO
```

Bank data: alcune considerazioni

- Le tecniche k-nearest neighbors non sembrano fornire buoni risultati
  - ✓ Rumore nei dati? (l'utilizzo di un k=5 aumenta di poco l'efficacia)
  - ✓ Training set limitato?
  - ✓ Funzioni distanza non appropriate? (l'algoritmo non riesce a sfruttare gli attributi numerici)
  - ✓ **Presenza di attributi ridondanti o non rilevanti?**

- E' possibile fare una verifica…
  - ✓ Selezionando un sottoinsieme di attributi
  - ✓ Eseguendo su di esso la classificazione
    - Sul training set che ha dato i risultati migliori bank data1.arff (senza campo id con children e age discretizzati) si esegue la selezione degli attributi (CfsSubsetEval) che restituisce:

      income + married + children
    - Si esegue la classificazione sulla versione normalizzata di questi attributi
    - In alternativa si possono utilizzare i primi attributi scelti dall'albero decisionale che ha fornito i risultati migliori (ossia quello basato bank data1.arff):

      children+income+married+mortgage+save act

Classificazione bank data

bank data1.arff: income + married + children

IB5– Training set 86.5%

```
  a   b   <-- classified as
223  51 |   a = YES
 30 296 |   b = NO
```

IB5– Cross val 81.5%

```
  a   b   <-- classified as
212  62 |   a = YES
 49 277 |   b = NO
```

IB5– Split 88.9%

```
 a  b   <-- classified as
75 21 |  a = YES
18 90 |  b = NO
```

bank data1.arff: children + income + married + mortgage + save act

IB5– Training set 90.3%

```
  a   b   <-- classified as
242  32 |   a = YES
 26 300 |   b = NO
```

IB5– Cross val 87.0%

```
  a   b   <-- classified as
232  42 |   a = YES
 36 290 |   b = NO
```

IB5– Split 84.8%

```
 a  b   <-- classified as
78 18 |  a = YES
13 95 |  b = NO
```

Dati di censimento

- Il dataset CensusTraining.arff riporta dati del censimento USA (http://cps.ipums.org/)
  - ✓ 1000 istanze per il training
  - ✓ 31561 istanze per la validazione

Attributo	Descrizione
age	Età in anni
workclass	Classe di lavoro
fnlwgt	“Final sampling weight” peso dell’istanza (campione) rispetto alla popolazione
education	Titolo ottenuto
education-num	Numero di anni di studio
marital-status	Stato civile
occupation	Occupazione
relationship	Tipo di relazione con il capo famiglia
race	Razza
sex	Sesso
capital-gain	Utili da capitali (plus valenza)
capital-loss	Perdite da capitali (minus valenza)
hours-per-week	Ore di lavoro settimanali
native-country	Nazionalità
Total Income	**L’individuo guadagna più o meno di 50K$**

Dati di censimento

- Obiettivo dello studio è trovare un modello che permetta di predire quali persone guadagnano più di 50K€
  - ✓ Ricerca di frodi fiscali

- Si proceda utilizzando la metodologia CRISP-DM
  1. Comprensione del dominio applicativo
  2. Comprensione dei dati
  3. Preparazione dei dati
  4. Creazione del modello
  5. Valutazione del modello e dei risultati
  6. *Deployment*

Dati di censimento

- C'è una forte correlazione tra i campi education ed education num
- Il campo fnlwgt sembra poco rilevante ai fini della determinazione della classe
- L'attributo native country è fortemente sbilanciato sul valore United States
  - ✓ Le selezioni fatte utilizzando questo attributo saranno sempre poco significative
- Alcuni campi presentano valori nulli ('?')
  - ✓ E' necessario valutare se calcolarli sostituendoli con media e moda
- Tra i campi che "a vista" meglio si prestano a fornire informazioni utili alla classificazione
  - ✓ Relationship, Race,Sex,Education – Education num
  - ✓ Il profilo di chi guadagna >50k$ è maschio, bianco, sposato con una educazione di livello superiore.
  - ✓ Dalla prima analisi non è possibile evincere se tra questi attributi esistano delle correlazioni e quindi debbano essere usati in alternativa

Dati di censimento

- Si comparino le performance degli algoritmi studiati (J48, JRip e IBK) utilizzando come training set i file
  - ✓ AdultTraining.arff
  - ✓ AdultTrainingSmall.arff
- In entrambi i casi si utilizzi come modalità di validazione il test set
  - ✓ AdultTest.arff
- Si verifichi in seguito come cambiano i risultati ottenuti dai due data set utilizzando le tecniche
  - ✓ AdaBoost
  - ✓ Bagging
- Si commentino i risultati

Dati di censimento

- L'utilità di calcolare i dati mancanti è verificata applicando gli algoritmi ai dati grezzi e ai dati modificati tramite il filtro ReplaceMissingValues

CensusTraining.arff

J48– Supplied TS 82.7%

```
     a     b   <-- classified as
 22571  1381 |     a = <=50K
  4082  3527 |     b = >50K
```

JRip– Supplied TS 82.6%

```
     a     b   <-- classified as
 21990  1962 |     a = <=50K
  3544  4065 |     b = >50K
```

IB5– Supplied TS 80.7%

```
     a     b   <-- classified as
 21430  2522 |     a = <=50K
  3575  4034 |     b = >50K
```

CensusTrainingNoMissing.arff

J48– Supplied TS 82.3%

```
a     b   <-- classified as
 22664  1288 |     a = <=50K
  4304  3305 |     b = >50K
```

JRip– Supplied TS 83.0%

```
a     b   <-- classified as
 21561  2391 |     a = <=50K
  2960  4649 |     b = >50K
```

IB5– Supplied TS 80.1%

```
a     b   <-- classified as
 19613  2340 |     a = <=50K
  3486  3801 |     b = >50K
```

- Si decide di mantenere i dati originali

Dati di censimento

- Le performance degli algoritmi sul training set ridotto sono:

CensusTrainingSmall.arff

J48– Supplied TS 75.9%

```
a     b   <-- classified as
23952     0 |     a = <=50K
 7609     0 |     b = >50K
```

JRip– Supplied TS 75.9%

```
a     b   <-- classified as
23952     0 |     a = <=50K
 7609     0  |     b = >50K
```

IB5– Supplied TS 76.7%

```
a     b   <-- classified as
22224  1728 |     a = <=50K
 5637  1972 |     b = >50K
```

- Riducendo il numero di attributi considerati sulla base del filtro CfsSubsetEval la performance dell'algoritmo di k-nearest neighbor migliora leggermente
  - ✓ Age + education-num + marital-status + relationship + capital gain + capital loss + hours-per-week

CensusTraining.arff

IB5– Supplied TS 80.7%

```
a     b   <-- classified as
21430  2522 |     a = <=50K
 3575  4034 |     b = >50K
```

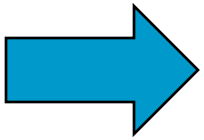

IB5– Supplied TS 80.9%

```
a     b   <-- classified as
21818  2134 |     a = <=50K
 3904  3705 |     b = >50K
```

- Cosa succede discretizzando gli attributi numerici?

Applicazione: marketing lift

- *Una ditta di collocamento possiede una banca dati contenente le informazioni (classe esclusa) relative a 50000 infermiere. Si vogliono contattare tramite posta tutte le infermiere appartenenti alla classe "**priority**". Tali infermiere saranno tutte inviate ad un insieme di ospedali che hanno fatto richiesta di nuove infermiere.*
- *L'operazione di invio delle lettere ha un costo fisso di 10,000 € e un costo individuale (per ogni infermiera contattata) pari a 5 €.*
- *Gli ospedali prenderanno in prova le infermiere selezionate dalla ditta e alla fine del periodo di prova pagheranno alla ditta 10 € per ogni infermiera che risulterà essere effettivamente una infermiera classificabile come appartenente alla classe "priority". Decidere quale modello, tra quelli studiati permette di ottenere potenzialmente il profitto maggiore e quante infermiere (in percentuale) devono essere contattate.*

- Verificare quale delle tecniche di classificazione studiate fornisce il modello che fornisce il **lift** maggiore
  - ✓ Dataset di training: nurseryTrain.arff
  - ✓ Tecnica di validazione 10 folds cross-validation

Applicazione: marketing lift

- Il **lift** è un indicatore che permette di compare più modelli di classificazione favorendo quelli che permettono di individuare un campione distorto della popolazione che massimizzi la probabilità di trovare istanze della classe desiderata Ci

$$\text{Lift}(ModelloX) = \frac{P(C_i \mid Campione)}{P(C_i \mid Popolazione)}$$

- Molto utilizzato in ambito marketing per selezionare i clienti su cui operare (campagne focalizzate).
  - ✓ La classe desiderata è quella degli utenti che risponderanno positivamente all'attività di marketing
- Calcolare il lift e il guadagno effettivo per J48 JRIP e IB1

Applicazione: marketing lift

- J48

```
   a    b    c    d    e   <-- classified as
3333    0    0    0    0 |    a = not_recom
   0    0    2    0    0 |    b = recommend
   0    0  239   89    0 |    c = very_recom
   0    0   63 3785  103 |    d = priority
   0    0    0   54 2332 |    e = spec_prior
```

- Error rate = 3.11%
- % TP stimata della popolazione = 39.51%
- % del campione rispetto alla popolazione = 3,928 / 10,000 = 39.28%
- % TP stimata del campione = 96.36%
- Lift(J48)=(3,785/3,928) / (3,951/10,000)=0.9636/0.3951=2.4389

- Costo su popolazione = -10,000€ - 50,000 × 5€ + 50,000 × 39.51% × 10€ = **- 260,000€** + **197,550€** = **- 62,450 €**
- Costo su campione = -10,000 € - 50,000 × 39.28% × 5€ + 50,000 × 39.28% × 96.36% × 10 = -**108,200€** + **189,251€ = + 81,051€**

Applicazione: marketing lift

- JRIP

```
    a    b    c    d    e   <-- classified as
 3333    0    0    0    0 |    a = not_recom
    0    0    2    0    0 |    b = recommend
    0    0  214  114    0 |    c = very_recom
    0    1  124 3719  107 |    d = priority
    0    0    0   35 2351 |    e = spec_prior
```

- Error rate = 3.81%
- % TP stimata della popolazione = 39.51%
- % del campione rispetto alla popolazione = 3,868 / 10,000 = 38.68%
- % TP stimata del campione = 96.15%
- Lift(JRIP)=(3,719/3,868) / (3,951/10,000)=0.9615/0.3951=2.4336

- Costo su popolazione = -10,000€ - 50,000 × 5€ + 50,000 × 39.51% × 10€ = **- 260,000€** + **197,550€** = **- 62,450 €**
- Costo su campione = -10,000 € - 50,000 × 38.68% × 5€ + 50,000 × 38.68% × 96.15% × 10 = -**108,200€** + **185,954€ = + 77,754€**

Applicazione: marketing lift

- IB1

```
   a    b    c    d    e   <-- classified as
3333    0    0    0    0 |    a = not_recom
   0    0    2    0    0 |    b = recommend
   0    0  194  134    0 |    c = very_recom
   0    0    0 3916   35 |    d = priority
   0    0    0   89 2297 |    e = spec_prior
```

- Error rate = 2.60%
- % TP stimata della popolazione = 39.51%
- % del campione rispetto alla popolazione = 4,139 / 10,000 = 41.39%
- % TP stimata del campione = 94.61%
- Lift(IB1)=(3,916/4,139) / (3,951/10,000)=0.9461/0.3951=2.3946

- Costo su popolazione = -10,000€ - 50,000 × 5€ + 50,000 × 39.51% × 10€ = **- 260,000€** + **197,550€** = **- 62,450 €**
- Costo su campione = -10,000 € - 50,000 × 41.39% × 5€ + 50,000 × 41.39% × 94.61% × 10 = -**113,475€** + **195,795€ = + 82,320€**

Considerazioni

- La tecnica di classificazione più idonea sembra essere quella dei k-mediani
- Le performance degli alberi decisionali non aumentano utilizzando tecniche di boosting
- Il risultato non dipende dalla componente variance del dataset ma piuttosto dalla componente bias
  - ✓ I decision boundary di questo data set sono difficilmente modellabili tramite segmenti paralleli agli assi

- Per il problema del lift non è detto che il classificatore migliore sia quello con accuracy o error rate minimi visto che siamo interessati agli errori commessi per una particolare classe
  - ✓ Classificazione cost based con costi più elevati per gli errori di interesse

Applicazione: marketing lift

- Cost SensitiveClassifier +J48

```
Cost Matrix                    a    b    c    d    e   <-- classified as
  0   1   1   1   1         3333    0    0    0    0 |    a = not_recom
  1   0   1   1   1            0    0    2    0    0 |    b = recommend
  1   1   0  10   1            0    0  308   20    0 |    c = very_recom
  1   1   1   0   1            0    0  161 3642  148 |    d = priority
  1   1   1  10   0            0    0    0   11 2375 |    e = spec_prior
```

- Error rate = 3.42%
- % TP stimata della popolazione = 39.51%
- % del campione rispetto alla popolazione = 3,673 / 10,000 = 36.73%
- % TP stimata del campione = 99.16%
- Lift(CSC+J48)=(3,642/3,673) / (3,951/10,000)=0.9916/0.3951=2.5096
- Costo su popolazione = -10,000€ - 50,000 × 5€ + 50,000 × 39.51% × 10€ = **- 260,000€** + **197,550€** = **- 62,450 €**
- Costo su campione = -10,000 € - 50,000 × 36.73% × 5€ + 50,000 × 36.73% × 99.16% × 10 = -**101,825€** + **182,107€ = + 80,282€**

Gli errori si riducono, ma la riduzione del campione controbiliancia la maggior precisione